FIAP — Faculdade de Informática e Administração Paulista

Challenge FIAP × Forzy

Processamento de Linguagem Natural, Chatbots & Virtual Agents

Gêmeo Digital para Monitoramento e Manutenção Preditiva de Motores Elétricos Industriais

Sprint 4 — Documentação Final da Solução PLN

Professor: Sergio Eduardo Palmiere

Integrantes — Grupo CodeX

Guilherme Gama	RM565293
Bruno Fernandes Nascimento	RM552574
Edgar Lódula de Assis	RM565260
Júlia Aben-Athar	RM566325
Igor Thiago Nakajima Vieira	RM563632

Repositório GitHub

https://github.com/guilhermegamabs/py-challenge-sprint-4-nlp

São Paulo, novembro de 2026

Resumo

A solução PLN tem quatro camadas, construídas uma por sprint e usadas em sequência:

Sprint	Camada	Entrega principal
1	Base linguística	glossário PT/EN de 170 termos, corpus estruturado de 84 campos, pipeline de normalização
2	Consulta semântica	busca híbrida (embeddings + lexical + filtro numérico) sobre o cadastro de 8 ativos
3	Geração e classificação	resumos de alerta em 3 níveis de severidade, classificação de eventos, relatório rastreável
3/4	Assistente RAG	troubleshooting sobre 5 manuais WEG, com estado operacional do ativo no prompt

O assistente RAG foi entregue junto com a Sprint 3, em agosto. Por isso, nesta sprint final não houve módulo novo. O trabalho foi corrigir as falhas que a avaliação anterior expôs, fazer todos os notebooks rodarem e documentar o resultado com os números reais.

Na avaliação final, o assistente passou a recusar **4 de 4** perguntas fora de escopo; na Sprint 3 eram 3. Além disso, a confiança mostrada ao operador deixou de ser "ALTA" em todas as respostas.

O custo dessas mudanças está medido e declarado neste documento:

- a faithfulness caiu de 0,743 para 0,678;
- uma pergunta legítima passou a ser recusada.

1. O que avançou da Sprint 3 até a apresentação final

1.1 Ponto de partida

A avaliação do próprio grupo já tinha registrado cinco problemas no assistente:

1. **Alucinação fora de escopo.** Perguntado sobre a configuração de um inversor *de outro fabricante* (F02), o modelo respondeu com instruções e citou documentos da WEG como fonte.
2. **Confiança sem informação.** O modelo declarou `Confiança: ALTA` nas 20 perguntas do gabarito, inclusive nas duas em que a recuperação trouxe o trecho errado. Um sinal que nunca muda não serve ao operador.
3. **Cópia do exemplo do prompt.** A resposta de T16 (vibração após o acoplamento) saiu praticamente igual ao exemplo de formato do prompt de sistema, que tratava de desalinhamento e correia.
4. **Número trocado.** Em T01, o limite de 155 °C da classe F virou 150 °C, com a marca de fonte ao lado.
5. **Notebook da Sprint 1 sem saídas.** Ele dependia de montar o Google Drive e nunca tinha sido executado fora do Colab.

1.2 O que foi feito

#	Ajuste	Onde	Problema que resolve
1	**Recusa determinística por limiar.** Se a relevância do melhor trecho recuperado fica abaixo de 0,60, o LLM nem é chamado e o assistente responde com uma recusa padrão.	`pln/assistente.py`	alucinação fora de escopo (F02)
2	**Confiança calculada pelo sistema.** A linha de confiança exibida é calculada pela recuperação (ALTA ≥ 0,85; MÉDIA ≥ 0,60). A confiança que o modelo declara fica só no registro, para comparação.	`pln/assistente.py`	confiança sempre ALTA
3	**Relevância sem bônus de contexto.** O score usado no limiar e na confiança é *denso + 0,35 × lexical*, sem os bônus de família e de ativo do re-ranking.	`pln/assistente.py`	o score composto inflava a confiança das perguntas com contexto
4	**Exemplo do prompt trocado** por um caso fictício de outro aparelho, sem números	`PROMPT_SISTEMA`	cópia do exemplo (T16)
5	**Verificador de números sem fonte literal.** Todo número da resposta que não aparece nos trechos, no estado do ativo ou na pergunta é listado no registro.	`numeros_sem_suporte()`	número trocado (T01) passa a ser detectado
6	**Consulta composta no diálogo.** No 2º turno em diante, a busca usa a pergunta anterior junto com a atual.	`Assistente.responder`	regressão causada pelo ajuste 1 (seção 1.4)
7	Notebooks das quatro sprints executados, com saídas visíveis	4 notebooks	reprodutibilidade
8	Comparativo antes/depois com a mesma régua	`scripts/comparar_sprint3.py`	evitar comparação enganosa (seção 1.5)

1.3 Três tentativas para o exemplo do prompt

Trocar o exemplo do prompt parecia o ajuste mais simples. Na prática, foi o que mais mexeu nos resultados. As três variantes foram avaliadas no gabarito completo, e todas estão preservadas em `relatorios/`:

Variante	Faithfulness	Fora de escopo recusadas	O que aconteceu
Sprint 3: desalinhamento e correia (dentro do corpus)	0,743	3 de 4	T16 copiou o exemplo
Iteração 1: compressor, "filtro a cada 2 000 horas"	0,760	4 de 4	**o exemplo vazou para T18**, e o verificador de números pegou o "2 000"
Iteração 2: só marcadores (`<causa tirada de um trecho> [FONTE 1]`)	0,638	2 de 4	o modelo perdeu o formato e várias respostas saíram com o corpo vazio
Final: geladeira, sem números, declarado fictício	0,678	4 de 4	sem vazamento, sem corpo vazio

O critério de escolha foi fixado antes de comparar os números, nesta ordem:

1 nenhum vazamento do exemplo e nenhuma resposta vazia;

2 recusa fora de escopo;

3 faithfulness.

A iteração 1 teve a maior faithfulness, mas uma resposta que recomenda "trocar o filtro a cada 2 000 horas" num motor elétrico é exatamente o erro que o assistente não pode cometer.

Lição registrada: só a redação do exemplo moveu a faithfulness de 0,64 a 0,76. Com 20 perguntas e um modelo de 3B, essa sensibilidade é do mesmo tamanho dos efeitos que queremos medir.

1.4 Uma regressão encontrada na demonstração e corrigida

Depois do limiar de recusa, a demonstração em diálogo mostrou um problema: **o 2º turno dos três cenários foi recusado.** Perguntas como "A corrente também subiu 10%. Isso muda o diagnóstico?" não têm o assunto explícito. Buscadas sozinhas, recuperam trechos sem relação e ficam abaixo de 0,60 (relevância de 0,39 a 0,56).

A correção foi buscar com a pergunta anterior junto com a atual. Com ela, os seis turnos foram respondidos, com relevância de 0,62 a 0,73. A versão com o defeito está em `relatorios/sprint4_iteracao3_cenarios_sem_consulta_composta.json`.

O caso mostra por que o gabarito sozinho não basta: ele roda sem memória e nunca teria exposto esse defeito.

1.5 Antes × depois

Para comparar, as respostas da Sprint 3 foram reavaliadas com o mesmo critério da Sprint 4: métricas sobre o *corpo* da resposta, sem a linha de confiança.

Na Sprint 3, a linha de confiança entrava no juiz NLI e contava como frase sem suporte. Por isso o valor publicado então (0,690) difere do 0,743 reavaliado. A diferença vem da régua, não do assistente.

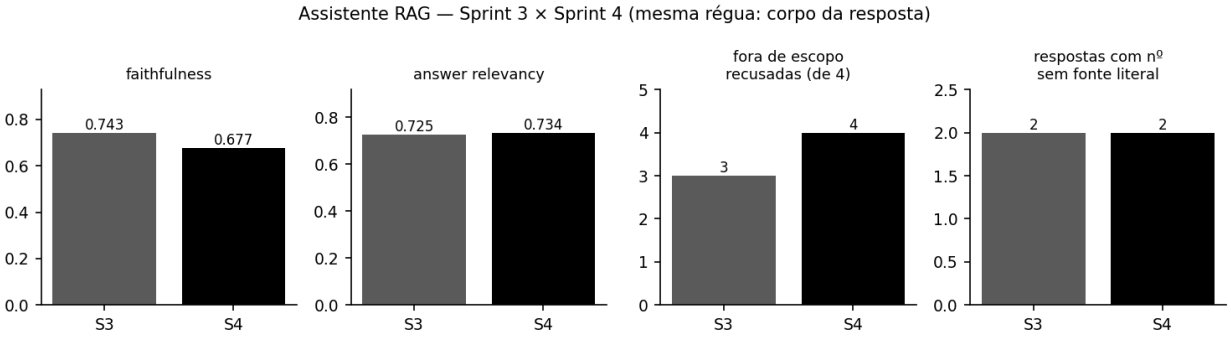


Figura 1 — Assistente RAG, Sprint 3 × Sprint 4, com a mesma régua de avaliação.

Métrica (20 perguntas + 4 fora de escopo)	**Sprint 3**	**Sprint 4**
Faithfulness (juiz NLI, por frase)	0,743	0,678
Answer relevancy	0,725	0,734
Perguntas fora de escopo recusadas	3 de 4	**4 de 4**
Confiança exibida	20 × ALTA	7 ALTA · 12 MÉDIA · 1 BAIXA
Respostas com citação de fonte	100%	95% (a 5% restante é a recusa de T13)
Respostas com número sem fonte literal	2 (não detectadas na época)	2 (detectadas e registradas)
Tempo médio por resposta (CPU)	20,3 s	19,9 s

Leitura honesta:

- **Ganho real:** a fronteira de escopo (F02 deixou de ser respondida) e uma confiança que varia conforme a recuperação.
- **Perda real:** faithfulness 0,065 menor e T13 recusada sem necessidade. Com a sensibilidade medida na seção 1.3, não dá para atribuir essa diferença de faithfulness a nenhum ajuste específico.

1.6 Notebooks executados

Notebook	Antes	Agora	Métricas reproduzidas
`sprint1_pln_corpus.ipynb`	0 de 24 células com saída (dependia do Drive)	24 de 24, sem erro	7 documentos, 69.671 tokens, vocabulário de 15.658
`sprint2_pln_consulta.ipynb`	executado	15 de 15	P@1 0,944 · R@3 1,000 (idênticos)
`sprint3_pln_alertas.ipynb`	executado	29 de 29	artefatos idênticos byte a byte aos de agosto
`sprint4_pln_rag.ipynb`	executado	18 de 18, com a nova seção 8 (antes × depois)	ver seção 1.5

A única mudança de código no notebook da Sprint 1 foi permitir execução local: o Drive só é montado quando o notebook roda no Colab.

1.7 Mantido, evoluído, substituído

Entregável da Sprint 3	Situação	Justificativa
Resumos de alerta por template (ROUGE-1 0,550)	**mantido**	rastreáveis, sem número inventado (checklist 100%); nada nesta sprint justificou trocar
Classificador híbrido zero-shot + regras (macro-F1 0,838)	**mantido**	o ganho é parcialmente ajuste ao corpus (seção 3.2); sem dados novos, mexer seria sobreajustar mais
Relatório operacional (38 de 38 linhas rastreáveis)	**mantido**	—
Índice RAG e retriever com re-ranking (MRR 0,758)	**mantido**	—
Confiança declarada pelo LLM	**substituído**	pela confiança calculada (seção 1.2, ajuste 2)
Prompt de sistema	**evoluído**	exemplo novo (seção 1.3)
Assistente	**evoluído**	limiar de recusa, verificador de números, consulta composta
Documento técnico das Sprints 3 e 4	**corrigido**	ver abaixo

Correções no que foi publicado em agosto:

- O documento da Sprint 3 dizia que a pergunta não recusada era F04 (vida útil do rolamento). O arquivo `fora_de_escopo.csv` da própria entrega mostra que F04 foi recusada e que a falha foi **F02** (inversor de terceiro).
- O notebook dizia "~3,5 min por resposta em CPU". O valor medido com o modelo quantizado em uso é ~20 s.

2. Diferenciais e resultados da solução

2.1 Métricas reais

Todos os números abaixo saem de arquivos versionados em `relatorios/` e foram reproduzidos nesta sprint.

Módulo	Métrica	Valor	Conjunto
Busca semântica (S2)	P@1 / R@3	0,944 / 1,000	18 consultas, 8 ativos
Resumos de alerta (S3)	ROUGE-1 / ROUGE-2 / ROUGE-L	0,550 / 0,296 / 0,405	24 alertas × referência manual
Resumos de alerta (S3)	checklist automático (10 critérios)	100%	24 alertas
Classificação de eventos (S3)	macro-F1: zero-shot / TF-IDF + LogReg / híbrido	0,603 / 0,763 / **0,838**	conjunto de teste, 168 eventos no total
Relatório operacional (S3)	linhas com âncora até o sensor	38 de 38	relatório semanal

Módulo	Métrica	Valor	Conjunto
Retriever (S4)	context recall@4 / MRR / precision@4	0,90 / 0,758 / 0,338	20 perguntas com gabarito de seção
Retriever (S4)	MRR sem → com re-ranking lexical	0,563 → 0,758	idem
Assistente (S4)	faithfulness / answer relevancy	0,678 / 0,734	idem
Assistente (S4)	recusa fora de escopo	4 de 4	4 perguntas
Assistente (S4)	recusa indevida no gabarito	1 de 20 (T13)	20 perguntas

2.2 Diferenciais técnicos

Domínio industrial específico. O vocabulário controlado vem dos documentos do fabricante:

- 170 termos PT/EN em 7 categorias, com tipos e causas de falha alinhados à tabela oficial WEG de danos em enrolamentos;
- as decisões de pré-processamento foram medidas, não presumidas. O stemming RSLP foi rejeitado porque juntava termos que o domínio distingue (*isolamento* × *isolante*).

Português técnico. Embeddings multilíngues e classificador NLI multilíngue. As respostas são em português, com números no formato brasileiro (vírgula decimal) e unidades preservadas.

Rastreabilidade até o sensor. Cada afirmação tem origem verificável:

- os resumos de alerta e o relatório trazem âncoras até a leitura de sensor (`[FONTE: leituras_sensores.csv | ...]`);
- as respostas do assistente marcam o trecho do manual (`[FONTE n]`) e o registro guarda documento, seção e página de cada trecho;
- o verificador de números lista o que não tem fonte literal.

Contexto operacional real no prompt. O estado do ativo calculado na Sprint 3 entra no prompt do assistente e orienta o retriever: situação (EM RISCO, EM OBSERVAÇÃO...) e os resumos dos alertas abertos. O operador pergunta "este motor"; o assistente sabe qual é e o que está acontecendo com ele.

Decisões críticas fora do LLM. Na versão final, quem decide se responde e com que confiança é o código, a partir de um sinal medido (a relevância da recuperação). O modelo de 3B redige; não arbitra.

Tudo offline, em CPU. Embeddings, juiz NLI, classificador zero-shot e LLM quantizado (Qwen2.5-3B, GGUF Q4_K_M) rodam localmente, sem chamada a API externa e sem GPU.

2.3 Demonstração documentada: falha mecânica no MT-008

Os três cenários (elétrico, mecânico e manutenção planejada) aparecem nos prints P09 a P11 do Anexo, na seção 7 do notebook `sprint4_pln_rag.ipynb` e, transcritos sem edição, em `evidencias/demo_cenarios_falha.md`. O cenário mecânico é reproduzido abaixo.

Estado injetado no prompt: EM RISCO, com alertas críticos abertos:

- temperatura do mancal +17,8 °C sobre o baseline por 5,1 dias;
- vibração global de 4,4 mm/s (+112,8% sobre o baseline).

> **Operador:** *A vibração deste motor mais que dobrou em cinco dias. O que verificar primeiro?*
>
> **Assistente:** *A primeira coisa a verificar é o alinhamento do motor [FONTE 1]. Em seguida, verifique o balanceamento do motor [FONTE 2]. Além disso, verifique o rolamento e a lubrificação do mancal [FONTE 1]. Se necessário, faça a inspeção e a substituição do rolamento [FONTE 1]. Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho: 0,68).*
>
> **Operador:** *O alinhamento foi conferido e está correto. O que mais pode causar isso?*

Assistente: *O desbalanceamento do motor também pode causar vibração [FONTE 2]. A temperatura do mancal foi a principal causa apontada [FONTE 1]. Outro fator a ser verificado é a lubrificação do rolamento [FONTE 2]. A vibração também pode ser causada por desalinhamento [FONTE 1]. Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho: 0,70).*

O que a demonstração mostra:

- **Funciona:** o assistente usa o estado do ativo (cita o mancal, que vem do alerta e não da pergunta) e mantém o fio do diálogo.
- **Falha 1:** no 2º turno, repete "desalinhamento" mesmo depois de o operador dizer que o alinhamento estava correto.
- **Falha 2:** cita como fonte trechos que não tratam de vibração. As marcas [FONTE 1] e [FONTE 2] apontam para as seções de isolação e de vida útil do motor (`evidencias/demo_cenarios_falha.md`).

As duas falhas estão catalogadas na seção 3.3.

As perguntas fora de escopo aparecem no print P08 e estão transcritas, lado a lado entre a Sprint 3 e a 4, em `evidencias/fora_de_escopo_antes_depois.md`. Os logs completos de execução estão em `evidencias/log_*.txt`; o print P13 mostra um trecho.

3. O que ficou pendente, por que e possíveis melhorias

3.1 Itens não concluídos do escopo

Item	Situação	Motivo
Integração dos resumos e do assistente ao painel do gêmeo digital	**não feita**	O painel Streamlit gera seus próprios resumos (Gemini 2.5 Flash, com template de reserva) e não consome o módulo `pln/`. As duas camadas foram desenvolvidas em paralelo e não houve prazo para unificar o contrato. É a primeira proposta da seção 4.
Avaliação com juiz LLM (RAGAS)	**não feita**	Exige um LLM juiz maior que o gerador; em CPU, sem chave de API, o custo de 20 perguntas × várias métricas era incompatível com o prazo. Usamos juiz NLI offline, mais rígido (seção 3.2).
Validação do limiar em conjunto independente	**não feita**	O limiar de 0,60 foi escolhido olhando as mesmas 24 perguntas em que é avaliado. Faltou tempo para escrever um segundo gabarito.
Cobertura de procedimentos de manutenção detalhados	**parcial**	O corpus indexado é majoritariamente de especificação: intervalos de relubrificação por carcaça e torques de aperto não estão no material em português.
Demonstração da solução em funcionamento	**concluída como sequência de prints**	O enunciado aceita vídeo ou sequência de prints; optamos pelos prints, que mostram as saídas reais dos notebooks executados. Estão no Anexo, ao fim deste documento.

Os itens citados no enunciado como exemplos de pendência foram **concluídos**: o re-ranking contextual do retriever, a avaliação com 20 perguntas de diagnóstico e a cobertura dos três cenários de falha.

3.2 Limitações conhecidas

Limitação	Evidência	Efeito
A confiança calculada mede a recuperação, não a resposta	faithfulness média por nível: ALTA 0,56 · MÉDIA 0,72	O nível diz se a documentação cobre o assunto, não se o modelo a usou bem. Não pode ser lido como probabilidade de acerto.
Nenhum limiar separa os grupos sem erro	T13 (0,545) fica abaixo de F02 (0,571); ver Figura 2	0,60 troca uma recusa indevida por uma alucinação evitada.
Sensibilidade ao prompt	faithfulness de 0,64 a 0,76 só trocando o exemplo	Diferenças menores que ~0,1 com 20 perguntas não são conclusivas.
Não determinismo do LLM	Com temperatura 0 e semente fixa, o mesmo 1º turno saiu com redação diferente em duas execuções (llama.cpp em CPU com várias threads)	Reexecutar a avaliação não reproduz os mesmos números exatos; os artefatos versionados são a referência.
Juiz NLI rígido com paráfrase	respostas corretas com vocabulário diferente do trecho são penalizadas	A faithfulness absoluta tende a ser subestimada; a comparação entre versões usa a mesma régua.
Citação nem sempre aponta o trecho certo	MT-008, 2º turno: as marcas [FONTE 1] e [FONTE 2] apontam para as seções de isolação e de vida útil do motor, que não tratam de vibração	A marca de fonte existe em 95% das respostas, mas não é verificada.
Corpus sintético	8 ativos, 24 alertas, 168 eventos, séries simuladas	As métricas validam o pipeline, não substituem dados de planta.
Regras do classificador ajustadas ao corpus	parte do ganho de 0,603 para 0,838 vem de regras escritas sobre os erros deste conjunto	Um corpus novo pode exigir revisar os marcadores.
Stopwords acentuadas na Sprint 1	"nao" aparece entre os termos mais frequentes: a lista de stopwords tem "não" e é aplicada depois da remoção de acentos	As estatísticas de frequência da Sprint 1 ficam levemente infladas. Não afeta as sprints seguintes, que normalizam de outro jeito.
Infraestrutura (Colab)	o LLM de 3B quantizado ocupa ~2 GB (arquivo GGUF) e leva ~20 s por resposta em CPU; no Colab gratuito a sessão cai por inatividade	As inferências caras vêm pré-computadas em `relatorios/`, e as células de recomputação estão sinalizadas.

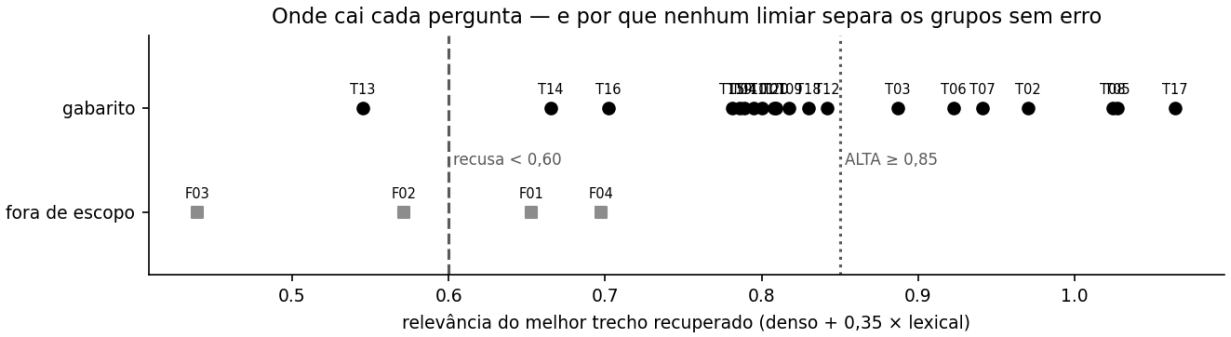


Figura 2 — Relevância do melhor trecho para cada pergunta. As duas distribuições se sobrepõem: nenhum limiar separa gabarito e fora de escopo sem erro.

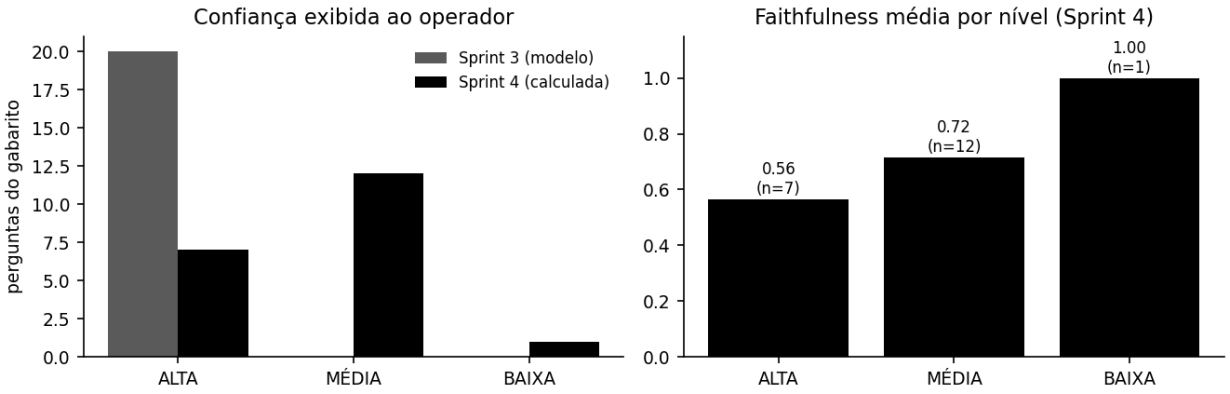


Figura 3 — À esquerda, a confiança exibida passou de constante a variável. À direita, ela não prevê faithfulness: o nível ALTA tem média menor que o MÉDIA. O único BAIXA é T13, cuja "resposta" é a recusa padrão; seu 1,00 não mede qualidade.

3.3 Casos de alucinação e recuperação incorreta

Caso	O que aconteceu	Contramedida	Estado
F02 (S3)	Instruções para configurar o inversor de um concorrente, citando a WEG	limiar de recusa	**resolvido**: recusa sem chamar o LLM
T16 (S3)	resposta copiada do exemplo do prompt	exemplo de outro aparelho, sem conteúdo técnico	**resolvido**: a resposta final trata de desbalanceamento e alinhamento com base no trecho
T18 (iteração 1)	"substituir o elemento filtrante a cada 2 000 horas" vazou do exemplo	detectado pelo verificador; exemplo trocado de novo	**resolvido** na versão final
T01	155 °C (classe F) vira 150 °C, em todas as versões	verificador lista "150" como sem fonte	**detectado, não corrigido**: o número ainda chega ao operador
T05	cálculo de potência útil com aritmética errada ("2% de 40 °C = 8 °C") e uma potência nominal inventada ("2.000 cv × 0,90 = 1.800 cv"; a pergunta não informa a potência)	verificador lista "32" e "1800"	**detectado, não corrigido**
T02, T07, T12	respostas que parafraseiam além do trecho recuperado (faithfulness ≤ 0,25)	—	**aberto**
T13	pergunta legítima (relevância 0,545) recusada	—	**efeito colateral aceito** do limiar
2º turno dos cenários	perguntas de seguimento recusadas pelo limiar	consulta composta com o turno anterior	**resolvido** (seção 1.4)
MT-008, 2º turno	volta a sugerir desalinhamento depois de o operador descartá-lo	—	**aberto**: o modelo de 3B não segura a restrição do diálogo

Contramedida planejada para os números. Quando o verificador encontrar número sem fonte, o sistema deve:

- rebaixar a confiança exibida para BAIXA;
- anexar um aviso explícito ("valor 150 não consta nas fontes — conferir no manual").

A detecção já existe, então o passo é pequeno. Não foi ligado nesta sprint porque mudaria as respostas avaliadas sem nova rodada de avaliação.

4. Proposta de evolução futura — "Ir além"

4.1 Integrar o módulo PLN ao painel do gêmeo digital

- **O que:** o painel Streamlit e a API FastAPI do front da Sprint 4 passam a consumir o módulo `pln/`, em vez de manter uma geração de resumo paralela. São três integrações:
- resumo de alerta por template, com rastreabilidade;
- estado operacional por ativo;
- assistente como uma aba "Perguntar ao manual" dentro do dashboard do ativo, com o estado do ativo já injetado.
- **Tecnologia:** o pacote `pln/` exposto como serviço na API FastAPI existente (endpoint `/assistente`, que já tem API Key e `trace_id`); o Streamlit chama a API.
- **Limitação resolvida:** hoje existem duas camadas de texto que não se conversam, e os resumos do painel (Gemini) não têm a rastreabilidade nem o checklist dos resumos da Sprint 3.
- **Impacto na Forzy:** o operador vê o alerta, lê a explicação rastreável e pergunta ao manual sem trocar de tela. O tempo entre o alerta e a primeira ação diminui.

4.2 Avaliação contínua com RAGAS e gabarito independente

- **O que:**
- escrever um segundo gabarito de 40 a 60 perguntas, com especialista de manutenção e sem ver o índice;
- recalibrar nele o limiar de recusa e as faixas de confiança;
- rodar a avaliação a cada mudança de prompt ou de modelo.
- **Tecnologia:** framework RAGAS (faithfulness, answer relevancy, context precision e recall com juiz LLM), mantendo o juiz NLI atual como métrica offline de controle e rodando em CI.
- **Limitação resolvida:**
- limiar ajustado no próprio conjunto de teste;
- sensibilidade a prompt de ±0,06 invisível com 20 perguntas;
- juiz NLI que penaliza paráfrase.
- **Impacto na Forzy:** mudança de prompt ou de modelo só vai para produção com número comparável; regressões como a do 2º turno (seção 1.4) seriam pegas antes da demonstração.

4.3 Base documental de manutenção e verificador de números ativo

- **O que:**
- indexar fichas de manutenção por carcaça, datasheets e procedimentos de relubrificação, inclusive em inglês, usando o glossário PT/EN da Sprint 1 para a ponte de idioma;
- transformar o verificador de números de *detector* em *bloqueio*: resposta com número sem fonte sai com confiança BAIXA e aviso explícito.
- **Tecnologia:** o mesmo pipeline de chunking por seção; expansão de consulta com os sinônimos do glossário; a regra em `numeros_sem_suporte()` passa a governar a confiança.
- **Limitação resolvida:**
- as falhas de recuperação T16/T19 e a recusa de T13 vêm de documentação ausente;
- T01 e T05 mostram que números errados ainda chegam ao operador.
- **Impacto na Forzy:** perguntas de manutenção, as mais frequentes em operação, passam a ter fonte; valores errados param de chegar ao operador com aparência de certeza.

5. Reprodutibilidade

Pasta `challenge-sprint-4/processamento-linguagem-natural/`:

Passo	Comando	Tempo (CPU)
Avaliar o assistente (gabarito, fora de escopo, cenários)	`python scripts/avaliar_assistente.py`	~12 min
Rodar só os cenários de diálogo	`python scripts/avaliar_assistente.py --so-cenarios`	~3 min
Comparativo Sprint 3 × Sprint 4	`python scripts/comparar_sprint3.py`	~7 min
Figuras e transcrições de evidência	`python scripts/gerar_evidencias.py`	segundos
Prints do Anexo (a partir dos notebooks executados)	`python scripts/gerar_prints.py`	~30 s
Notebook da Sprint 4	`python scripts/build_notebook_sprint4.py` e depois executar `sprint4_pln_rag.ipynb`	~1 min
Este documento (.docx e .pdf)	`python scripts/gerar_documento_final.py`	segundos

- **Modelo local:** a variável `MODELO_LLM` aceita o caminho de um `.gguf` já baixado. Sem ela, o modelo é baixado do Hugging Face.
- **Artefatos versionados:** todas as saídas usadas neste documento estão em `relatorios/`. As iterações descartadas ficam em `relatorios/sprint4_iteracao1/` e `relatorios/sprint4_iteracao2/`, e as respostas da Sprint 3 em `relatorios/sprint3_baseline/`.

Anexo — Solução em funcionamento: sequência de prints

Esta sequência substitui o vídeo demonstrativo, conforme a alternativa prevista no enunciado. Cada print é uma célula real de um notebook executado, com o código, a saída e o número de execução visíveis. Nada foi recalculado nem editado para as imagens: elas são geradas a partir dos `.ipynb` salvos por `scripts/gerar_prints.py`, e os arquivos ficam em `evidencias/prints/`.

A ordem acompanha o fluxo da solução:

- **P01 e P02 (Sprint 1):** base linguística;
- **P03 e P04 (Sprint 2):** consulta semântica;
- **P05 e P06 (Sprint 3):** geração e classificação de texto;
- **P07 a P13 (Sprint 4):** assistente RAG, incluindo os três cenários de falha.

Sprint 1 — Base linguística

Sprint 1 — pipeline de pré-processamento aplicado às causas de falha

sprint1_pln_corpus.ipynb · célula [17]

In [17]:
```
# Causas de falha — texto de pré-processamento
print("=== CAUSAS DE FALHA — APÓS PIPELINE ===\n")
df_causas = df[df["tipo"] == "causa_de_falha"]

for _, row in df_causas.iterrows():
    tokens = preprocessar(row["valor_original"])
    print(f"[{row['id']}] {row['valor_original'][:70]}")
    print(f"      → {tokens[:10]}")
    print()
```

Out:
```
=== CAUSAS DE FALHA — APÓS PIPELINE ===

[CA001] Contaminação interna do motor
      → ['contaminacao', 'interna']

[CA002] Falha do esmalte de isolação do fio
      → ['falha', 'esmalte', 'isolacao', 'fio']

[CA003] Falha do verniz de impregnação
      → ['falha', 'verniz', 'impregnacao']

[CA004] Rápidas oscilações na tensão de alimentação
      → ['rapidas', 'oscilacoes', 'tensao', 'alimentacao']

[CA005] Degradação do material isolante por ressecamento causada por excesso d
      → ['degradacao', 'material', 'isolante', 'ressecamento', 'causada', 'excesso', 'temperatura']

[CA006] Sobretensão ou subtensão na rede de alimentação
      → ['sobretensao', 'subtensao', 'rede', 'alimentacao']

[CA007] Ventilação deficiente — temperatura ambiente elevada, motor em local c
      → ['ventilacao', 'deficiente', 'temperatura', 'ambiente', 'elevada', 'local', 'confinado', 'obstrucao', 'entradas']

[CA008] Conexão incorreta dos cabos de ligação do motor
      → ['conexao', 'incorreta', 'cabos', 'ligacao']

[CA009] Excessivo número de partidas em tempo curto
      → ['excessivo', 'numero', 'partidas', 'tempo', 'curto']

[CA010] Excessiva dificuldade na partida do motor — elevada queda de tensão, i
      → ['excessiva', 'dificuldade', 'partida', 'elevada', 'queda', 'tensao', 'inercia', 'e/ou', 'torque', 'carga']

[CA011] Circuito auxiliar aberto — problema no capacitor, platinado ou centríf
      → ['circuito', 'auxiliar', 'aberto', 'problema', 'capacitor', 'platinado', 'centrifugo']
```

P01 — O pipeline de pré-processamento aplicado às causas de falha do corpus: remoção de acentos, expansão de abreviações, stopwords técnicas e tokenização.

Sprint 1 — estatísticas do corpus

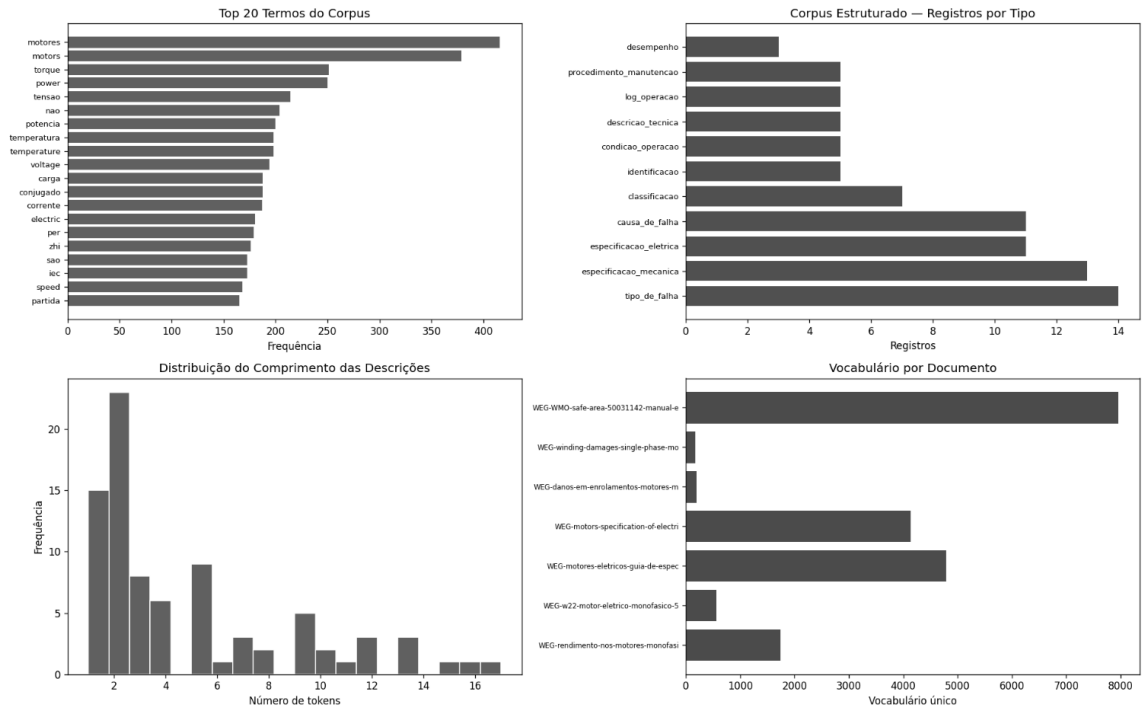
sprint1_pln_corpus.ipynb · célula [12]

In [12]:
```
# ── 6.3 Visualizações ──────────────────────────────────────────
fig, axes = plt.subplots(2, 2, figsize=(16, 10))

# 1) Top 20 termos
top20 = freq.most_common(20)
termos_t, cnts_t = zip(*top20)
axes[0,0].barh(list(reversed(termos_t)), list(reversed(cnts_t)), color="#2b6cb0")
axes[0,0].set_xlabel("Frequência")
axes[0,0].set_title("Top 20 Termos do Corpus")
axes[0,0].tick_params(axis="y", labelsize=8)

# 2) Registros por tipo
tipo_counts = df["tipo"].value_counts()
axes[0,1].barh(tipo_counts.index, tipo_counts.values, color="#276749")
# … (+22 linhas — código completo no notebook)
```

Out:



Out:
```
Gráfico salvo.
```

P02 — Estatísticas do corpus processado: termos mais frequentes, registros por tipo de campo, comprimento das descrições e vocabulário por documento.

Sprint 2 — Consulta semântica

Sprint 2 — consulta semântica em linguagem natural sobre o cadastro

sprint2_pln_consulta.ipynb · célula [15]

In [15]:

```
def consulta_completa(query, k=3):
    print(f'\n>>> Operador: {query!r}\n')
    for r in buscar(query, k=k):
        print(f'  [{r["ativo_id"]}] score={r["score"]:.3f}')
        print(f'    {descrever_ativo(r["ativo_id"])}')


for q in [
    'motor da area 3',
    'equipamento de 220V com maior temperatura',
    'motor que esta esquentando muito',
    'motor mais potente da planta',
]:
    consulta_completa(q)
```

Out:

```
>>> Operador: 'motor da area 3'

  [MT-002] score=1.000
    Atencao em W22-132M-4P-15CV-3F: temperatura fora da faixa ideal (72C). Leituras: 220V, 36.8A, 1755 RPM.
  [MT-003] score=0.980
    CRITICO: Motor W22-160L-2P-30CV-3F com temperatura em nivel critico (81C). Acionar manutencao. Leituras: 220V, 68.5A, 3548 RPM.
  [MT-006] score=0.960
    Motor W22-90L-6P-2CV-3F operando dentro dos parametros normais. Ultima leitura: 220V, 5.9A, 1150 RPM.

>>> Operador: 'equipamento de 220V com maior temperatura'

  [MT-008] score=1.000
    CRITICO: Motor W22-112M-4P-7.5CV-3F com temperatura em nivel critico (89C). Acionar manutencao. Leituras: 220V, 18.5A, 1745 RPM.
  [MT-003] score=0.980
    CRITICO: Motor W22-160L-2P-30CV-3F com temperatura em nivel critico (81C). Acionar manutencao. Leituras: 220V, 68.5A, 3548 RPM.
  [MT-002] score=0.960
    Atencao em W22-132M-4P-15CV-3F: temperatura fora da faixa ideal (72C). Leituras: 220V, 36.8A, 1755 RPM.

>>> Operador: 'motor que esta esquentando muito'

  [MT-008] score=1.000
    CRITICO: Motor W22-112M-4P-7.5CV-3F com temperatura em nivel critico (89C). Acionar manutencao. Leituras: 220V, 18.5A, 1745 RPM.
  [MT-003] score=0.980
    CRITICO: Motor W22-160L-2P-30CV-3F com temperatura em nivel critico (81C). Acionar manutencao. Leituras: 220V, 68.5A, 3548 RPM.
  [MT-002] score=0.960
    Atencao em W22-132M-4P-15CV-3F: temperatura fora da faixa ideal (72C). Leituras: 220V, 36.8A, 1755 RPM.

>>> Operador: 'motor mais potente da planta'

  [MT-005] score=1.000
    Motor W22-225S-4P-75CV-3F operando dentro dos parametros normais. Ultima leitura: 380V, 98.5A, 1775 RPM.
  [MT-007] score=0.980
    Motor WMagnet-IPM-50CV-3F operando dentro dos parametros normais. Ultima leitura: 380V, 65.2A, 1798 RPM.
  [MT-003] score=0.960
    CRITICO: Motor W22-160L-2P-30CV-3F com temperatura em nivel critico (81C). Acionar manutencao. Leituras: 220V, 68.5A, 3548 RPM.
```

P03 — Consultas em linguagem natural do operador ("motor que está esquentando muito", "equipamento de 220V com maior temperatura") respondidas com o ativo certo e uma descrição textual do estado.

Sprint 2 — Precision@k e Recall@k nas 18 consultas-teste

sprint2_pln_consulta.ipynb · célula [13]

In [13]:
```
metricas_cols = ['P@1', 'R@1', 'P@3', 'R@3', 'P@5', 'R@5']

print('=== Media global ===')
print(df_eval[metricas_cols].mean().round(3))

print('\n=== Media por categoria ===')
print(df_eval.groupby('categoria')[metricas_cols].mean().round(3))
```

Out:
```
=== Media global ===
P@1    0.944
R@1    0.815
P@3    0.444
R@3    1.000
P@5    0.267
R@5    1.000
dtype: float64

=== Media por categoria ===
                   P@1    R@1    P@3  R@3    P@5  R@5
categoria
coloquial        1.000  0.875  0.417  1.0  0.250  1.0
en_abreviacao    1.000  1.000  0.333  1.0  0.200  1.0
filtro_numerico  1.000  0.778  0.556  1.0  0.333  1.0
literal          0.667  0.667  0.333  1.0  0.200  1.0
operador         1.000  0.767  0.533  1.0  0.320  1.0
```

P04 — Precision@k e Recall@k nas 18 consultas-teste, por categoria: P@1 de 0,944 e R@3 de 1,000.

Sprint 3 — Geração e classificação

Sprint 3 — resumos de alerta gerados por severidade

sprint3_pln_alertas.ipynb · célula [8]

In [8]:
```
resumos = gerar_resumos(alertas)
df_resumos = pd.DataFrame(resumos)
df_resumos["resumo_referencia"] = df_resumos["alerta_id"].map(referencias)

for sev in ("critico", "moderado", "leve"):
    exemplo = next(r for r in resumos if r["severidade"] == sev)
    print(f"### {sev.upper()}  ({exemplo['template_id']})")
    print(exemplo["texto"])
    print()
```

Out:
```
### CRITICO  (T-CRIT-01)
ALERTA CRÍTICO — motor W22-160L-2P-30CV-3F (Área 3 — Ventilador de Exaustão). A corrente de linha atingiu desvio severo de +25,7% sobre o
baseline de 72,1 A de forma sustentada por 5,6 dias, com valor de pico em 90,7 A. Risco de atuação das proteções e parada não programada.
Intervenção imediata requerida: avaliar sobrecarga mecânica e proteções antes de manter o ativo em regime — acionar manutenção no turno corrente.
[ALT-001 | sensor: corrente_a | pico: 11/06 às 12h00 | baseline 7d = 72,1 A | janela movel: 3h]

### MODERADO  (T-MOD-01)
Alerta moderado detectado no motor W22-100L-2P-3CV-1F (Linha de Produção A — Bomba Centrífuga 01). A temperatura do mancal apresentou desvio de
+9,9 C acima do baseline nas últimas 6 horas, atingindo 55,8 C. Recomenda-se verificação programada dentro das próximas 24 horas: inspeção do
mancal e revisão do plano de lubrificação. [ALT-005 | sensor: temperatura_mancal_c | pico: 10/06 às 22h00 | baseline 7d = 46,7 C | janela movel:
3h]

### LEVE  (T-LEVE-01)
Registro informativo no motor W22-132M-4P-15CV-3F (Área 3 — Compressor Principal). A corrente de linha apresentou variação de +7,1% em relação ao
baseline de 39 A nas últimas 18 horas, sem ultrapassar os limites operacionais. Nenhuma ação imediata requerida: confrontar a leitura com o
regime de carga do processo. [ALT-013 | sensor: corrente_a | pico: 11/06 às 15h00 | baseline 7d = 39 A | janela movel: 3h]
```

P05 — Resumos de alerta gerados a partir dos desvios dos sensores, um por nível de severidade, com recomendação e rastreabilidade até a leitura de origem.

Sprint 3 — classificação de eventos: híbrido × zero-shot × TF-IDF

sprint3_pln_alertas.ipynb · célula [19]

In [19]:
```
pred_zs["pred_hibrido"] = cls.ajustar_por_regras(pred_zs)
zs_teste = pred_zs[pred_zs["evento_id"].isin(teste["evento_id"])]
av_hibrido = cls.avaliar(zs_teste["categoria_gold"], zs_teste["pred_hibrido"],
                         nome="zero_shot+regras")
av_hibrido_total = cls.avaliar(pred_zs["categoria_gold"], pred_zs["pred_hibrido"],
                               nome="zero_shot+regras_total")
print("macro-F1 híbrido (teste):", av_hibrido["macro_f1"])
print("macro-F1 híbrido (168 registros):", av_hibrido_total["macro_f1"])
```

Out:
```
macro-F1 híbrido (teste): 0.8377
macro-F1 híbrido (168 registros): 0.7975
```

sprint3_pln_alertas.ipynb · célula [20]

In [20]:
```
display(cls.tabela_f1(av_zs, av_hibrido, av_base))
display(cls.matriz_confusao_df(av_zs))
display(cls.matriz_confusao_df(av_hibrido))
display(cls.matriz_confusao_df(av_base))
```

Out:

	zero_shot_mdeberta	zero_shot+regras	tfidf_logreg
manutencao_corretiva	0.143	0.963	0.741
manutencao_preventiva	0.667	0.783	0.759
anomalia_eletrica	0.759	0.786	0.929
anomalia_mecanica	0.591	0.800	0.690
operacao_normal	0.857	0.857	0.696
MACRO-F1	0.603	0.838	0.763

Out:

	pred:manutencao_corretiva	pred:manutencao_preventiva	pred:anomalia_eletrica	pred:anomalia_mecanica	pred:operacao_normal
real:manutencao_corretiva	1	0	1	11	0
real:manutencao_preventiva	0	7	3	3	1
real:anomalia_eletrica	0	0	11	2	1
real:anomalia_mecanica	0	0	0	13	1
real:operacao_normal	0	0	0	1	12

Out:

	pred:manutencao_corretiva	pred:manutencao_preventiva	pred:anomalia_eletrica	pred:anomalia_mecanica	pred:operacao_normal
real:manutencao_corretiva	13	0	0	0	0
real:manutencao_preventiva	0	9	3	1	1
real:anomalia_eletrica	0	0	11	2	1
real:anomalia_mecanica	1	0	0	12	1
real:operacao_normal	0	0	0	1	12

Out:

	pred:manutencao_corretiva	pred:manutencao_preventiva	pred:anomalia_eletrica	pred:anomalia_mecanica	pred:operacao_normal
real:manutencao_corretiva	10	1	0	2	0
real:manutencao_preventiva	2	11	0	1	0
real:anomalia_eletrica	0	0	13	0	1
real:anomalia_mecanica	1	2	0	10	1
real:operacao_normal	1	1	1	2	8

P06 — Classificação dos eventos operacionais: macro-F1 do híbrido (0,838) contra o zero-shot (0,603) e o TF-IDF + LogReg (0,763), com F1 por categoria.

Sprint 4 — Assistente RAG

Sprint 4 — retriever com e sem re-ranking

sprint4_pln_rag.ipynb · célula [6]

In [6]:
```
metricas_ret = json.loads((RELATORIOS / "metricas_retriever.json").read_text(encoding="utf-8"))
display(pd.DataFrame(metricas_ret["por_configuracao"]))
display(pd.DataFrame(metricas_ret["por_k"])[["k", "context_precision", "context_recall", "hit_rate", "mrr"]])
```

Out:

	configuracao	context_precision	context_recall	hit_rate	mrr
0	denso_puro	0.2500	0.8	0.8	0.5625
1	denso_lexical	0.3375	0.9	0.9	0.7583
2	denso_lexical_contexto	0.3125	0.9	0.9	0.6958

Out:

	k	context_precision	context_recall	hit_rate	mrr
0	1	0.6500	0.65	0.65	0.6500
1	3	0.4000	0.90	0.90	0.7583
2	4	0.3375	0.90	0.90	0.7583
3	6	0.2500	0.90	0.90	0.7583
4	10	0.1650	0.90	0.90	0.7583

P07 — Retriever sobre os manuais WEG: o re-ranking lexical eleva o MRR de 0,563 para 0,758 nas 20 perguntas com gabarito.

Sprint 4 — perguntas fora de escopo recusadas

sprint4_pln_rag.ipynb · célula [14]

In [14]:
```
fora = (pd.read_csv(RELATORIOS / "fora_de_escopo.csv")
        if (RELATORIOS / "fora_de_escopo.csv").exists() else pd.DataFrame(columns=["id", "pergunta", "resposta", "recusou"]))
print(f"recusa explícita em {fora['recusou'].sum()} de {len(fora)} perguntas\n")
for _, linha in fora.iterrows():
    print(f"[{linha['id']}] {linha['pergunta']}")
    print("   ", linha["resposta"][:260].replace("\n", " "), "\n")
```

Out:
```
recusa explícita em 4 de 4 perguntas

[F01] Qual o preço de um motor W22 de 15 cv e o prazo de entrega?
    Não há informações sobre o preço ou prazo de entrega dos motores W22 em nenhuma das fontes fornecidas. Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho: 0,65).

[F02] Como configuro o inversor de frequência da marca concorrente modelo XYZ-500?
    A documentação técnica disponível não trata deste assunto com aderência suficiente para uma resposta segura. Consulte a engenharia de manutenção ou o canal responsável pela informação. Confiança: BAIXA — calculada pela recuperação (relevância do melhor trecho:

[F03] Qual a previsão de chuva para a planta amanhã?
    A documentação técnica disponível não trata deste assunto com aderência suficiente para uma resposta segura. Consulte a engenharia de manutenção ou o canal responsável pela informação. Confiança: BAIXA — calculada pela recuperação (relevância do melhor trecho:

[F04] Qual é a vida útil restante, em horas, do rolamento do MT-008?
    Não há informações específicas sobre a vida útil restante do rolamento do MT-008 em nenhum dos trechos fornecidos. Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho: 0,70).
```

P08 — As 4 perguntas fora de escopo recusadas. F02 e F03 são recusadas pelo limiar, sem chamar o modelo; F01 e F04, pelo próprio modelo.

Sprint 4 — cenário de falha elétrica (MT-007)

sprint4_pln_rag.ipynb · célula [15]

In [15]:
```
caminho_cen = RELATORIOS / "cenarios_demo.json"
cenarios = json.loads(caminho_cen.read_text(encoding="utf-8")) if caminho_cen.exists() else []

for c in cenarios:
    print("=" * 78)
    print(f"CENÁRIO: {c['cenario'].replace('_', ' ').upper()} — ativo {c['ativo_id']}")
    if c.get("estado"):
        print(f"Estado: {c['estado']['situacao']}")
        for a in c["estado"]["alertas"][:2]:
            print("  •", a[:150])
    for i, turno in enumerate(c["dialogo"], start=1):
        print(f"\n--- turno {i}")
        print("OPERADOR :", turno["pergunta"])
        print("ASSISTENTE:", turno["resposta"][:700])
# … (+3 linhas — código completo no notebook)
```

Out:
```
==============================================================================
CENÁRIO: ANOMALIA ELETRICA — ativo MT-007
Estado: EM OBSERVAÇÃO — desvio moderado em acompanhamento
  • Alerta moderado detectado no motor WMagnet-IPM-50CV-3F (Linha de Produção A — Extrusora Principal). O fator de potência apresentou desvio de -0,08 aba
  • Alerta moderado detectado: WMagnet-IPM-50CV-3F opera com temperatura do enrolamento em 75,1 C, desvio +13,7 C sobre a referência de 61,5 C nas últimas

--- turno 1
OPERADOR : O fator de potência deste motor caiu de 0,95 para 0,88. O que pode explicar isso?
ASSISTENTE: [FONTE 1] O fator de potência (pf) é uma medida da eficiência do motor, indicando a proporção da potência real que o motor usa em relação à potência nominal. [FONTE 2] Um desvio moderado no fator de potência pode indicar sobrecarga ou problemas de carga. [FONTE 3] O alerta moderado detectado sugere que o motor opera com carga acima do regime. [FONTE 4] A temperatura do enrolamento em 75,1°C, além do desvio de -0,08, pode indicar sobrecarga ou problemas de refrigeração. [FONTE 1] A recomendação de verificação programada dentro das próximas 24 horas sugere que a causa provável é sobrecarga ou problemas de refrigeração.
Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho:
trechos  : guia_especificacao p.43, guia_especificacao p.58, guia_especificacao p.9

--- turno 2
OPERADOR : A corrente também subiu 10%. Isso muda o diagnóstico?
ASSISTENTE: [FONTE 1] A subida da corrente, em conjunto com o desvio do fator de potência, sugere sobrecarga ou problemas de carga. [FONTE 2] A recomendação de verificação programada dentro das próximas 24 horas indica a necessidade de avaliação do regime de carga. [FONTE 3] A temperatura do enrolamento em 75,1°C, além do desvio de +13,7°C, sugere problemas de refrigeração. [FONTE 4] A causa provável é sobrecarga ou problemas de refrigeração, conforme a documentação disponível. [FONTE 1] A subida da corrente não altera o diagnóstico, pois a avaliação do regime de carga é a recomendação mais importante.
Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho: 0,72).
trechos  : guia_especificacao p.9, guia_especificacao p.20, guia_especificacao p.58
```

P09 — Cenário de falha elétrica no MT-007: queda do fator de potência, com o estado do ativo injetado no prompt e dois turnos de diálogo.

Sprint 4 — cenário de falha mecânica (MT-008)

sprint4_pln_rag.ipynb · célula [15]

In [15]:
```
caminho_cen = RELATORIOS / "cenarios_demo.json"
cenarios = json.loads(caminho_cen.read_text(encoding="utf-8")) if caminho_cen.exists() else []

for c in cenarios:
    print("=" * 78)
    print(f"CENÁRIO: {c['cenario'].replace('_', ' ').upper()} — ativo {c['ativo_id']}")
    if c.get("estado"):
        print(f"Estado: {c['estado']['situacao']}")
        for a in c["estado"]["alertas"][:2]:
            print("  •", a[:150])
    for i, turno in enumerate(c["dialogo"], start=1):
        print(f"\n--- turno {i}")
        print("OPERADOR :", turno["pergunta"])
        print("ASSISTENTE:", turno["resposta"][:700])
# … (+3 linhas — código completo no notebook)
```

Out:
```
==========================================================================
CENÁRIO: ANOMALIA MECANICA — ativo MT-008
Estado: EM RISCO — alertas críticos abertos
  • ALERTA CRÍTICO — motor W22-112M-4P-7.5CV-3F (Linha de Produção B — Misturador Industrial). A temperatura do mancal atingiu desvio severo de
+17,8 C so
  • ALERTA CRÍTICO: W22-112M-4P-7.5CV-3F em condição severa. Leitura de vibração global registrada em 4,4 mm/s (+112,8% vs. baseline) de forma
sustentada

--- turno 1
OPERADOR : A vibração deste motor mais que dobrou em cinco dias. O que verificar primeiro?
ASSISTENTE: A primeira coisa a verificar é o alinhamento do motor [FONTE 1]. Em seguida, verifique o balanceamento do motor [FONTE 2]. Além
disso, verifique o rolamento e a lubrificação do mancal [FONTE 1]. Se necessário, faça a inspeção e a substituição do rolamento [FONTE 1].
Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho: 0,68).
trechos  : guia_especificacao p.15, guia_especificacao p.35, guia_especificacao p.33

--- turno 2
OPERADOR : O alinhamento foi conferido e está correto. O que mais pode causar isso?
ASSISTENTE: O desbalanceamento do motor também pode causar vibração [FONTE 2]. A temperatura do mancal foi a principal causa apontada [FONTE 1].
Outro fator a ser verificado é a lubrificação do rolamento [FONTE 2]. A vibração também pode ser causada por desalinhamento [FONTE 1].
Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho: 0,70).
trechos  : guia_especificacao p.15, guia_especificacao p.35, guia_especificacao p.13
```

P10 — Cenário de falha mecânica no MT-008: vibração dobrada e mancal aquecido. O assistente usa o alerta aberto e mantém o diálogo no segundo turno.

Sprint 4 — cenário de manutenção planejada (MT-004)

sprint4_pln_rag.ipynb · célula [15]

In [15]:
```
caminho_cen = RELATORIOS / "cenarios_demo.json"
cenarios = json.loads(caminho_cen.read_text(encoding="utf-8")) if caminho_cen.exists() else []

for c in cenarios:
    print("=" * 78)
    print(f"CENÁRIO: {c['cenario'].replace('_', ' ').upper()} — ativo {c['ativo_id']}")
    if c.get("estado"):
        print(f"Estado: {c['estado']['situacao']}")
        for a in c["estado"]["alertas"][:2]:
            print("  •", a[:150])
    for i, turno in enumerate(c["dialogo"], start=1):
        print(f"\n--- turno {i}")
        print("OPERADOR :", turno["pergunta"])
        print("ASSISTENTE:", turno["resposta"][:700])
# … (+3 linhas — código completo no notebook)
```

Out:
```
==========================================================================
CENÁRIO: MANUTENCAO PREVENTIVA — ativo MT-004
Estado: ESTÁVEL COM DESVIO — apenas desvios leves

--- turno 1
OPERADOR : Este motor vai ficar parado por três meses. Que cuidados de armazenamento devo tomar?
ASSISTENTE: Como o motor está parado há apenas três meses, não há necessidade de realizar a manutenção descrita nos trechos [FONTE 2] e [FONTE
3]. No entanto, para evitar a formação de óleo no rolamento, recomenda-se armazenar o motor horizontalmente, com óleo ISO VG 68 no rolamento, e
girar o eixo semanalmente [FONTE 2]. Além disso, é recomendável relubrificar os rolamentos abertos antes do comissionamento do motor, se o
período de armazenamento for superior a seis meses [FONTE 2]. Não há necessidade de desmontar ou trocar os ímãs permanentes neste caso [FONTE 1].
Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho: 0,62).
trechos  : manual_wmo p.20, manual_wmo p.16, manual_wmo p.16

--- turno 2
OPERADOR : E o que preciso inspecionar quando ele voltar a operar?
ASSISTENTE: Para o retorno ao operação, inspecione a temperatura ambiente e a presença de desvios leves no estado do ativo [FONTE 1]. Verifique a
lubrificação dos rolamentos e a presença de óleo no rolamento [FONTE 2].
Confiança: MÉDIA — calculada pela recuperação (relevância do melhor trecho: 0,65).
trechos  : manual_wmo p.20, guia_especificacao p.35, manual_wmo p.16
```

P11 — Cenário de manutenção planejada no MT-004: cuidados de armazenamento e inspeção na volta à operação.

Sprint 4 — antes × depois e limiar de recusa

sprint4_pln_rag.ipynb · célula [16]

In [16]:
```
caminho_cmp = RELATORIOS / "comparativo_sprint3_sprint4.json"
if caminho_cmp.exists():
    cmp = json.loads(caminho_cmp.read_text(encoding="utf-8"))
    tabela = pd.DataFrame({"Sprint 3": cmp["sprint3"], "Sprint 4": cmp["sprint4"]})
    display(tabela.astype(str))
    print("Sprint 3 como publicado (com a linha de confiança no juiz):",
          cmp["sprint3_publicado_original"])
else:
    print("execute `python scripts/comparar_sprint3.py`")
```

Out:

	Sprint 3	Sprint 4
faithfulness_medio	0.7433	0.6775
answer_relevancy_medio	0.7248	0.7338
respostas_com_citacao_pct	100.0	95.0
fora_de_escopo_recusadas	3 de 4	4 de 4
fora_de_escopo_nao_recusadas	['F02']	[]
confianca_exibida	{'ALTA': 20}	{'MÉDIA': 12, 'ALTA': 7, 'BAIXA': 1}
confianca_do_modelo	{'ALTA': 20}	{'ALTA': 18, 'NAO_GERADA': 1, 'MÉDIA': 1}
respostas_com_numero_sem_suporte	['T01', 'T05']	['T01', 'T05']
tempo_medio_s	20.3	19.9

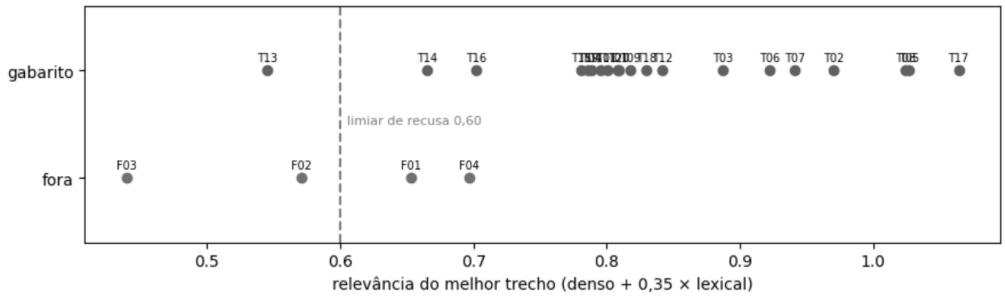
Out:
```
Sprint 3 como publicado (com a linha de confiança no juiz): {'faithfulness_medio': 0.69, 'answer_relevancy_medio': 0.7358, 'observacao':
'calculado com a linha de confiança dentro da resposta'}
```

sprint4_pln_rag.ipynb · célula [18]

In [18]:
```
# Relevância de recuperação: gabarito x fora de escopo (por que 0,60)
import matplotlib.pyplot as plt

if caminho_cmp.exists():
    rel = cmp["relevancia_recuperacao"]
    fig, ax = plt.subplots(figsize=(9, 2.8))
    ax.scatter(list(rel["gabarito_por_id"].values()), [1] * len(rel["gabarito_por_id"]),
               label="gabarito (20)", color="#2b6cb0")
    ax.scatter(list(rel["fora_de_escopo_por_id"].values()), [0] * len(rel["fora_de_escopo_por_id"]),
               label="fora de escopo (4)", color="#c05621")
    for pid, v in {**rel["gabarito_por_id"], **rel["fora_de_escopo_por_id"]}.items():
        ax.annotate(pid, (v, 1 if pid.startswith("T") else 0), fontsize=7,
                    xytext=(0, 6), textcoords="offset points", ha="center")
    ax.axvline(0.60, ls="--", color="gray")
# … (+6 linhas — código completo no notebook)
```

Out:



P12 — Antes × depois com a mesma régua, e a relevância de cada pergunta em relação ao limiar de recusa de 0,60.

Sprint 4 — log real da avaliação do assistente (execução em CPU)

log_avaliacao_assistente_sprint4_final.txt

```
# execucao: 2026-11-04T15:30:42-03:00
== retriever ==
{'configuracao': 'denso_puro', 'context_precision': 0.25, 'context_recall': 0.8, 'hit_rate': 0.8, 'mrr': 0.5625}
{'configuracao': 'denso_lexical', 'context_precision': 0.3375, 'context_recall': 0.9, 'hit_rate': 0.9, 'mrr': 0.7583}
{'configuracao': 'denso_lexical_contexto', 'context_precision': 0.3125, 'context_recall': 0.9, 'hit_rate': 0.9, 'mrr': 0.6958}
== respostas do assistente ==
backend: llama_cpp | modelo: F:/hf-cache/hub/models--Qwen--Qwen2.5-3B-Instruct-GGUF/snapshots/7dabda4d13d513e3e842b20f0d435c732f172cbe/qwen2.5-3b-
instruct-q4_k_m.gguf
[1/20] T01 (31.0s)
[2/20] T02 (21.0s)
[3/20] T03 (27.3s)
[4/20] T04 (15.4s)
[5/20] T05 (32.5s)
[6/20] T06 (24.6s)
[7/20] T07 (20.6s)
[8/20] T08 (23.8s)
[9/20] T09 (18.5s)
[10/20] T10 (14.8s)
[11/20] T11 (19.6s)
[12/20] T12 (17.2s)
[13/20] T13 (0.0s)
[14/20] T14 (19.8s)
[15/20] T15 (20.5s)
[16/20] T16 (15.2s)
[17/20] T17 (19.4s)
[18/20] T18 (17.1s)
[19/20] T19 (20.4s)
[20/20] T20 (19.4s)
== fora de escopo ==
[fora de escopo] F01 recusou=1
[fora de escopo] F02 recusou=1
[fora de escopo] F03 recusou=1
[fora de escopo] F04 recusou=1
== cenarios de demonstracao ==
[cenario anomalia_eletrica] turno respondido
[cenario anomalia_eletrica] turno respondido
[cenario anomalia_mecanica] turno respondido
[cenario anomalia_mecanica] turno respondido
[cenario manutencao_preventiva] turno respondido
[cenario manutencao_preventiva] turno respondido
== metricas de geracao ==
…
```

P13 — Trecho do log real da avaliação em CPU: métricas do retriever, tempo de cada resposta, recusa por limiar em T13 (0,0 s) e as 4 recusas fora de escopo.