DOCUMENTO TÉCNICO

Sprint 1 — Fundamentos do Ativo e da Base de Dados

Challenge FIAP + Forzy
Processamento de Linguagem Natural

Digital Twin — Monitoramento e Manutenção Preditiva de Motores Elétricos Industriais

Ativo de referência	WEG W22 — Motor Elétrico Monofásico 3 CV / 2,2 kW
Data	25/04/2026
Notebook principal	sprint1_pln_corpus.ipynb
Glossário	dados/glossario_pt_en.json (170 termos)
Corpus estruturado	dados/corpus_estruturado.csv (84 registros)

1. Visão Geral do Projeto

Este documento descreve tecnicamente a Sprint 1 do projeto Forzy, desenvolvido no âmbito do Challenge FIAP. O objetivo central é construir a base linguística padronizada que sustentará todos os módulos de PLN do sistema de digital-twin para manutenção preditiva de motores elétricos industriais.

1.1 Objetivo

Transformar textos heterogêneos — extraídos de placas de identificação, manuais técnicos, fichas de cadastro e logs de operação — em um corpus estruturado, limpo e indexável, preparado para as etapas de consulta semântica e geração de linguagem natural das sprints seguintes.

1.2 Ativo de Referência

Campo	Valor
Fabricante	WEG
Modelo	W22
Potência	2,2 kW (3 CV)
Carcaça	100L — Ferro fundido FC-200
Frequência	60 Hz
Número de polos	2
Rotação nominal	3.525 rpm
Tensão nominal	110-127 / 220-254 V
Corrente nominal	25,0-21,7 / 12,5-10,8 A
Grau de proteção	IP55
Classe de isolamento	F
Regime de serviço	S1 — Contínuo
Refrigeração	IC411 — TFVE
Eficiência (100%)	81,8%
Massa aproximada	38,6 kg

2. Fontes de Dados Utilizadas

Foram utilizados 7 documentos PDF oficiais WEG, cobrindo especificações técnicas, terminologia do domínio, normas e vocabulário de falhas para motores monofásicos.

Documento	Idioma	Págs.	Uso principal
WEG W22 Motor Elétrico Monofásico — Catálogo	PT	12	Especificações técnicas, componentes
WEG Guia de Especificação de Motores Elétricos	PT	68	Terminologia do domínio
WEG Specification Guide — Electric Motors	EN	68	Par EN para glossário bilíngue
WEG Rendimento nos Motores Monofásicos	PT	5	Terminologia de desempenho e ensaios
WEG Danos em Enrolamentos — Motores Monofásicos	PT	1	Falhas reais e causas (tabela oficial WEG)
WEG Winding Damages — Single-Phase Motors	EN	1	Par EN para vocabulário de falhas
WEG Manual Instalação, Operação e Manutenção	PT/EN/outros	62	Procedimentos operacionais

Nota: Os guias de especificação PT e EN (68 páginas cada) são o mesmo documento em dois idiomas, permitindo alinhamento direto de termos por número de seção (ex: §1.2.1 = Conjugado / Torque).

3. Estrutura do Notebook

O arquivo **sprint1_pln_corpus.ipynb** contém 39 células organizadas em 12 seções. Cada seção cobre um entregável específico da sprint.

Seção	Células	O que faz
1. Instalação	1	Instala pdfplumber, nltk, pandas, matplotlib, unidecode
2. Montar Drive	1	Conecta ao Google Drive e autentica o acesso
3. Imports e Caminhos	1	Define DRIVE_BASE, BASE (PDFs) e DADOS (artefatos)
4. Carregamento dos PDFs	1	Extrai texto de todos os PDFs com pdfplumber
5. Pipeline de Pré-proc.	4	Abreviações, stopwords, tokenização, stemming
6. Aplicação ao Corpus	1	Aplica pipeline a todos os documentos
7. Estatísticas do Corpus	4	Frequência, vocabulário, comprimento, gráficos
8. Vocabulário de Falhas	3	Análise e alinhamento PT/EN das falhas WEG
9. Glossário PT/EN	3	Carrega, visualiza e exporta o glossário
10. Corpus Estruturado	2	Carrega CSV e verifica completude dos campos
11. Avaliação do Stemming	2	Compara vocabulário com/sem RSLP e decide
12. Estrutura de Diretórios	1	Documenta naming convention e árvore de pastas
13. Decisões de Padronização	1	Tabela com 10 decisões e justificativas técnicas

4. Detalhamento de Cada Seção

Seção 1 — Instalação de Dependências

Instala as bibliotecas Python necessárias para execução no Google Colab:

- **pdfplumber** — extração de texto de PDFs preservando layout
- **nltk** — tokenização, stopwords e stemmer RSLP para português
- **pandas** — manipulação do corpus estruturado em DataFrame
- **matplotlib** — geração dos gráficos estatísticos
- **unidecode** — normalização de encoding (remove acentos de forma segura)

Seção 2 — Conexão ao Google Drive

Monta o Google Drive no ambiente Colab via **google.colab.drive.mount()**. Após a autenticação, os arquivos ficam acessíveis em **/content/drive/MyDrive/**.

Seção 3 — Imports e Configuração de Caminhos

Define três variáveis de caminho que são usadas por todas as seções seguintes:

```
DRIVE_BASE = /content/drive/MyDrive/Forzy BASE = DRIVE_BASE / 'Documentos do Motor' # onde estao os PDFs DADOS = DRIVE_BASE / 'dados' # onde serao salvos os artefatos
```

A célula também baixa os recursos NLTK necessários (stopwords, RSLP, punkt) e valida que os 7 PDFs estão acessíveis no Drive.

Seção 4 — Carregamento dos Documentos PDF

Itera sobre todos os PDFs encontrados em **BASE.rglob('*.pdf')** e extrai o texto página a página usando **pdfplumber**. O resultado é o dicionário **corpus_raw**:

```
corpus_raw = { 'WEG-w22-motor-eletrico-...pdf': { 'paginas': 12, 'texto': ['texto pag 1', 'texto pag 2', ...] }, ... # mais 6 documentos }
```

Por que pdfplumber? Preserva o layout da página e extrai texto com maior fidelidade que bibliotecas como PyPDF2, especialmente em documentos técnicos com tabelas e colunas.

Seção 5 — Pipeline de Pré-processamento Textual

Implementa o pipeline em 6 etapas sequenciais. É o núcleo técnico da sprint (35% da avaliação).

Etapa	Função	Justificativa
1. Normalização de encoding	unidecode(texto)	Elimina variações de encoding entre docs PT e EN sem perda semântica
2. Expansão de abreviações	expandir_abreviacoes(texto)	30+ padrões regex mapeiam abreviações industriais WEG para forma completa
3. Limpeza e padronização	lower() + regex	Minúsculas, remove pontuação excessiva, normaliza espaços
4. Tokenização	word_tokenize(NLTK)	Tokenizador ciente do português, respeita hífens e barras (IP55, B3D)
5. Remoção de stopwords	STOPWORDS (PT+EN+domínio)	Lista combinada cobre corpus multilíngue; lista de domínio remove ruído específi
6. Stemming RSLP (opcional)	RSLPStemmer()	Avaliado e desativado por padrão — colapsa termos técnicos distintos

Dicionário de abreviações industriais (amostra):

Abreviação	Expansão	Abreviação	Expansão
rot.	rotacao	superaquec.	superaquecimento
tens.	tensao	lubrif.	lubrificacao
corr.	corrente	manut.	manutencao
temp.	temperatura	vibr.	vibracao
pot.	potencia	deslig.	desligamento
freq.	frequencia	verif.	verificacao
conj.	conjugado	insp.	inspecao
S1	regime continuo S1	TFVE	totalmente fechado ventilacao externa
DOL	partida direta	VFD	inversor de frequencia

Seção 6 — Aplicação do Pipeline ao Corpus Completo

Aplica a função **preprocessar()** a cada documento do corpus_raw, gerando o dicionário **corpus_processado** com tokens limpos (com e sem stemming) e métricas por documento:

```
corpus_processado = { 'nome_doc.pdf': { 'tokens': [...], # lista de tokens limpos
'tokens_stem': [...], # com stemming RSLP 'n_chars': 222154, 'n_tokens': 18432,
'vocabulario': 3201 }, ... }
```

Seção 7 — Estatísticas do Corpus

Gera 4 métricas e 4 visualizações salvas na pasta dados/:

Métrica	O que mede
Tokens totais	Volume total de palavras após pré-processamento de todos os docs
Vocabulário único	Número de termos distintos no corpus — riqueza lexical
Razão type/token	Proporção vocab/tokens — indica densidade terminológica
Comprimento médio (tokens)	Tamanho médio das descrições do corpus estruturado

Arquivo	Conteúdo
estatisticas_corpus.png	Painel 2x2: top 20 termos, registros por tipo, distribuição de comprimento, vocab por doc
frequencia_falhas.png	Frequência de cada tipo de falha no corpus documental WEG
glossario_categorias.png	Distribuição de termos do glossário por categoria

Também gera **dados/estatisticas_corpus.json** com todas as métricas em formato estruturado para uso nas sprints seguintes.

Seção 8 — Análise do Vocabulário de Falhas

Extrai e analisa os termos de falha reais extraídos dos documentos oficiais WEG *Danos em Enrolamentos* (PT) e *Winding Damages* (EN). Esta seção é diretamente relevante para o módulo de manutenção preditiva do Forzy.

Tipo de Falha (PT)	Tipo de Falha (EN)
Curto entre espiras no enrolamento principal	Short circuit between turns in the main winding
Curto entre espiras no enrolamento auxiliar	Short circuit between turns in the auxiliary winding
Curto entre enrolamentos principal e auxiliar	Short circuit between main and auxiliary winding
Curto na conexao	Short circuit in the connection
Curto na saida da ranhura	Short circuit at the end of the slot
Rotor travado	Stuck rotor
Sobreaquecimento do enrolamento principal	Overheating in the main winding

Sobreaquecimento do enrolamento auxiliar	Overheating in the auxiliary winding
Metade do enrolamento principal sobreaquecido	Overheating in half of the main winding

Seção 9 — Glossário Bilíngue PT/EN

Carrega o arquivo **dados/glossario_pt_en.json** e exibe estatísticas, gráfico de distribuição e amostra de termos por categoria.

Categoria	Termos	Fonte
conceito_tecnico	58	Guia de Especificação WEG (alinhamento PT↔EN por número de seção)
campo_placa_motor	39	Catálogo W22 / Ficha Técnica
tipo_de_falha	25	Danos em Enrolamentos WEG (PT e EN)
norma_classificacao	19	Normas ABNT / IEC / WEG
causa_de_falha	12	Danos em Enrolamentos WEG
componente	11	Catálogo W22 + Manual de Manutenção
procedimento_manutencao	6	Manual de Instalação e Operação WEG
TOTAL	**170**	

Metodologia de alinhamento PT↔EN: os guias de especificação WEG existem em PT (68 págs.) e EN (68 págs.) com a mesma estrutura de seções numeradas. A extração de headings via regex e o alinhamento pelo número de seção (§1.2.1, §1.5.4...) gera pares terminológicos precisos sem tradução automática.

Seção 10 — Corpus Estruturado do Ativo

Carrega e inspeciona o arquivo **dados/corpus_estruturado.csv**, exibindo o corpus completo e verificando a completude dos 8 campos obrigatórios.

Tipo de Campo	Registros	IDs	Descrição
identificacao	5	AT001-AT005	TAG, descrição, fabricante, modelo, localização
especificacao_eletrica	11	ET001-ET011	Tensão, corrente, frequência, fator de potência...
especificacao_mecanica	13	EM001-EM013	Carcaça, rotação, conjugado, materiais...
classificacao	7	NR001-NR007	IP55, Classe F, S1, IC411, B3D...
condicao_operacao	5	OP001-OP005	Temperatura ambiente, altitude, tempo rotor bloqueado
desempenho	3	EF001-EF003	Eficiência em 50%, 75% e 100% de carga
descricao_tecnica	5	DC001-DC005	Trechos textuais do catálogo W22
log_operacao	5	LG001-LG005	Logs simulados de SCADA com abreviações reais
tipo_de_falha	14	FA001-FA009E	Tipos de falha em PT e EN
causa_de_falha	11	CA001-CA011	Causas de falha extraídas da tabela WEG
procedimento_manutencao	5	PR001-PR005	Procedimentos do manual de instalação WEG

TOTAL	**84**		

Seção 11 — Avaliação do Impacto do Stemming

Compara o vocabulário resultante do pipeline com e sem stemming RSLP, identificando casos de colapso semântico problemático para o domínio técnico:

Termo A	Stem A	Termo B	Stem B	Problema
isolamento	isol	isolante	isol	Colapso
aquecimento	aqu	sobreaquecimento	aqu	Colapso
contaminacao	cont	contaminar	cont	Colapso
refrigeracao	refrig	refrigerar	refrig	Colapso
enrolamento	enrol	enrolamentos	enrol	Redundante (OK)

Decisao: pipeline executado SEM stemming por padrao. O RSLP colapsa termos tecnicos distintos ('isolamento' e 'isolante' tem semanticas diferentes no dominio de motores). Alternativa recomendada para as sprints seguintes: lematizacao com spaCy pt_core_news_sm.

Seções 12 e 13 — Estrutura e Decisões de Padronização

Documenta a estrutura de diretórios, naming convention dos artefatos e as 10 decisões de padronização com justificativas técnicas.

5. Arquivos Gerados

Arquivo	Formato	Conteúdo	Gerado por
glossario_pt_en.json	JSON	170 termos bilíngues PT/EN em 7 categorias	Script build_glossario.py
corpus_estruturado.csv	CSV	84 registros do ativo com 8 colunas de metadados	Script build_corpus.py
corpus_estruturado.json	JSON	Mesmo corpus em formato JSON	Script build_corpus.py
estatisticas_corpus.json	JSON	Métricas do pipeline: vocab, freq, comprimento	Célula 7 do notebook
estatisticas_corpus.png	PNG	Painel 2x2 com 4 gráficos estatísticos	Célula 7 do notebook
frequencia_falhas.png	PNG	Frequência de termos de falha no corpus	Célula 8 do notebook
glossario_categorias.png	PNG	Distribuição do glossário por categoria	Célula 9 do notebook
corpus_raw.json	JSON	Texto bruto extraído dos 7 PDFs	Script de extração
sprint1_pln_corpus.ipynb	IPYNB	Notebook Colab com pipeline completo (39 células)	Entregável principal

Estrutura de diretórios no Google Drive:

```
Forzy/ ■■■ Documentos do Motor/ ■ ■■■ Artigos Tecnicos/ ■ ■■■ Catalogos Tecnicos de Produtos/ ■ ■■■ Guias de Instalacao, Configuracao e Operacao/ ■ ■■■ Novos/ <- danos em enrolamentos + manual manutencao ■■■ dados/ ■ ■■■ glossario_pt_en.json ■ ■■■ corpus_estruturado.csv ■ ■■■ corpus_estruturado.json ■ ■■■ estatisticas_corpus.json ■ ■■■ estatisticas_corpus.png ■ ■■■ frequencia_falhas.png ■ ■■■ glossario_categorias.png ■■■ sprint1_pln_corpus.ipynb
```

6. Decisões de Padronização

Decisão	Justificativa Técnica
Texto normalizado em minúsculas sem acentos (unidecode)	Elimina variações de encoding entre documentos PT e EN. Permite comparação case-insensitive e
Abreviações expandidas por dicionário regex fixo	Documentos WEG usam formas abreviadas inconsistentes. Expansão por regex é reproduzível, auc
Stopwords PT + EN + domínio combinadas	Corpus multilíngue (manuais EN, operação PT). Listas separadas perderiam termos. Lista de domín
Stemming RSLP desativado por padrão	RSLP colapsa pares técnicos distintos (isolamento/isolante, aquecimento/sobreaquecimento). Reco
Corpus em CSV + JSON	CSV para análise em pandas/Excel por qualquer membro da equipe. JSON para ingestão direta no
IDs prefixados por tipo (ET001, FA003, CA007...)	Filtragem e rastreabilidade da origem de cada registro. Facilita joins e consultas nas sprints seguinte
Siglas de norma mantidas (IC411, B3D, IP55, SAE 1040)	São identificadores internacionais de norma. Normalizá-los quebraria a rastreabilidade com a docum
Vocabulário de falhas reais extraído dos docs WEG	Termos extraídos diretamente da tabela oficial WEG (Danos em Enrolamentos). Garante vocabulári
Logs de operação simulados incluídos no corpus	Representam o texto heterogêneo de SCADA/ordens de serviço. Necessários para testar o pipeline
Glossário alinhado por número de seção (não por tradução)	O guia WEG existe em PT e EN com mesma numeração de seções. Alinhamento por §numero gara

7. Cobertura dos Critérios de Avaliação

Critério	Peso	Onde está atendido
Qualidade e abrangência do glossário e padronização terminológica	25%	Seção 9 do notebook + dados/glossario_pt_en.json 170 termos, 7 categorias, alinhamento PT/EN por documento oficial WEG
Implementação e documentação do pipeline de pré-processamento	35%	Seções 5 a 7 do notebook 6 etapas documentadas, dicionário de 30+ abreviações, avaliação do stemming RSL
Qualidade do corpus estruturado e aderência ao projeto Forzy	25%	Seção 10 do notebook + dados/corpus_estruturado.csv 84 registros, 11 tipos, inclui falhas reais WEG para manutenção preditiva
Reprodutibilidade e organização dos artefatos entregues	15%	Seções 12 e 13 do notebook Naming convention, estrutura de diretórios, decisões documentadas, notebook repro

Todos os critérios de avaliação estão cobertos. O notebook é totalmente reproduzível via Runtime → Executar tudo no Google Colab, desde que os PDFs e arquivos de dados estejam na estrutura correta no Google Drive (Meu Drive / Forzy /).